

Rosberto. Plataforma para la gestión, carga y despliegue de Modelos de Visión y Acción en el Unitree G1 Edu para estandarizar el proceso de investigación universitaria

Alejandro Roa Aparicio

Alisson Dayana Navarro Rodriguez

Juan Pablo Quiroga Lugo

Universidad EAN

Proyecto de grado

Zoraima Oñates Flórez

30 de agosto de 2026

Resumen

En los últimos años, la investigación en robótica ha impulsado el desarrollo de aplicaciones de inteligencia artificial para robots humanoides. Entre las más comunes está el robot Unitree G1 Edu+29dof, con modelos LVA (Visión-Lenguaje-Acción) y técnicas como el aprendizaje reforzado y el aprendizaje por imitación, lo que facilita el entrenamiento y la comprensión del entorno por parte de los robots. Sin embargo, implementar sistemas de control basados en aprendizaje automático a partir de una simulación o de un modelo entrenado con un dataset presenta desafíos relacionados con la complejidad de las interfaces para desplegar modelos en el robot y con la recopilación de datos de entrenamiento, lo que dificulta la estandarización de los procesos de investigación sobre el robot Unitree G1 Edu+29dof. El siguiente trabajo propone el desarrollo de ROSberto una plataforma orientada a la recolección de datasets, gestión, carga y despliegue de modelos LVA (Visión-Lenguaje-Acción) con el propósito de simplificar el desarrollo de aplicaciones de aprendizaje robótico sobre el robot Unitree G1 Edu+29dof.

**Rosberto. Plataforma para la gestión, carga y despliegue de Modelos de Visión y Acción en
el Unitree G1 Edu para estandarizar el proceso de investigación universitaria**

Índice

Introducción	7
Problema	7
Justificación	9
Objetivos	11
Objetivo General	11
Objetivos Específicos	11
Robótica humanoide y aprendizaje robótico	12
Aprendizaje por imitación	13
Learning from Demonstration y adquisición de habilidades	14
Teleoperación robótica	15
Teleoperación mediante realidad virtual e interfaces inmersivas	16
Calidad y eficiencia de los datos de entrenamiento	16
Estandarización de datasets robóticos	17
LeRobot como paradigma de estandarización	17
Políticas de aprendizaje robótico	18
Diffusion Policies	19
Transformers para robótica	20
Vision-Language-Action Models	21
OpenVLA y modelos abiertos	21
Modelos fundacionales para robótica humanoide	22
Simulación y aprendizaje Sim-to-Real	23
Gestión del ciclo de vida de modelos	23

Abstracción de hardware	25
Middleware y orquestación	25
Reproducibilidad en investigación robótica	26
Democratización de la investigación en robótica	27
Unitree G1 Education Edition como plataforma de investigación	27
The Construct Robotics Institute	28
Integración de los conceptos en el ciclo de aprendizaje robótico	28
Relación conceptual con Rosberto	29
Metodología	31
Resultados	36
Conclusiones	37

Índice de figuras

Índice de cuadros

1. Matriz de Acciones Metodológicas y Resultados Esperados (MAM-RE) 31

Introducción

El desarrollo contemporáneo de la robótica humanoide ha dejado de ser un campo de investigación exclusivo de simulación para convertirse en una de las fronteras más dinámicas de la Inteligencia Artificial Física (*Physical AI*) (Bjorck et al., 2025). Plataformas como el robot bipedal humanoide Unitree G1 Edu combinan un diseño mecánico avanzado de hasta 29 grados de libertad con la capacidad de ejecutar tareas complejas de locomoción y manipulación bimanual en entornos no estructurados (Yan et al., 2026). Para dotar a estos robots de capacidades autónomas, la investigación científica se ha volcado hacia el uso de Modelos de Visión y Acción (VLA) y paradigmas de aprendizaje robótico como el Aprendizaje por Imitación (*Imitation Learning*) y el Aprendizaje por Refuerzo (*Reinforcement Learning*) (Seo et al., 2025; Yan et al., 2026).

En este contexto surge Rosberto, una plataforma *middleware* de código abierto diseñada bajo el ecosistema de ROS 2. El propósito de esta infraestructura es estandarizar y simplificar el proceso de investigación universitaria sobre el Unitree G1 Edu, actuando como un puente entre la adquisición de datos de teleoperación, la gestión de datasets multimodales bajo el estándar *LeRobot* (Cadene et al., 2026) y el despliegue en tiempo real de políticas de acción inteligentes. Al unificar estos subcomponentes en un flujo de trabajo optimizado, Rosberto permite que estudiantes e investigadores colaboren activamente sobre una base común, reduciendo la distancia que tradicionalmente separa el desarrollo de algoritmos de su ejecución física en el *hardware* real.

Problema

A pesar del vertiginoso avance en algoritmos de aprendizaje robótico, el despliegue práctico de políticas de control autónomo en robots humanoides sigue enfrentando un cuello de botella crítico: la falta de procesos y herramientas estandarizadas para la gestión y carga de modelos. Tradicionalmente, enseñar una nueva tarea de manipulación a un robot humanoide requiere un flujo fragmentado e ineficiente que abarca la recolección manual de miles de imágenes, la anotación manual de cuadros delimitadores, el escaneo láser en 3D de objetos y el entrenamiento de modelos de percepción específicos (Yan et al., 2026). Este flujo de trabajo

convencional consume típicamente varios días o semanas por cada nueva habilidad y demanda el uso de *hardware* de escaneo especializado (Yan et al., 2026).

Aunque recientemente se han diseñado pipelines modulares basados en modelos fundacionales que reducen el ciclo de preparación a aproximadamente 30 minutos (Yan et al., 2026), estas herramientas se encuentran dispersas en repositorios independientes y carecen de una interfaz común. Como consecuencia, el proceso de desarrollo en las universidades es irregular, lento y dependiente de herramientas aisladas diseñadas para subcomponentes específicos (Cadene et al., 2026).

Esta fragmentación genera dos problemas fundamentales en el ámbito académico y de pregrado:

- **Curva de aprendizaje prohibitiva:** los estudiantes de ingeniería deben invertir meses de trabajo en configurar sistemas operativos, compilar *drivers* de bajo nivel en terminales de línea de comandos, resolver problemas de dependencias de CUDA/PyTorch y coordinar protocolos de red complejos (como transmisiones UDP o seriales) antes de poder cargar su primer modelo de control de movimiento.
- **Falta de acumulación colectiva de conocimiento:** al no existir un formato unificado o una plataforma que centralice los experimentos, cada grupo de investigación se ve obligado a iniciar el desarrollo desde cero, impidiendo que el conocimiento científico avance de manera incremental mediante la reutilización de datasets y políticas previas.

Finalmente, la brecha de acceso se ve agravada por factores socioeconómicos. Un robot humanoide de última generación como el Unitree G1 Edu tiene un costo estimado entre \$42,000 y \$66,000 USD según su configuración, cifra inalcanzable para la gran mayoría de las instituciones educativas de países emergentes, lo que centraliza la investigación y el conocimiento tecnológico en unos pocos laboratorios privilegiados.

Justificación

El desarrollo de la plataforma Rosberto se justifica por la necesidad apremiante de democratizar la robótica humanoide y de dotar a la comunidad académica de herramientas que reduzcan de forma drástica los tiempos de preparación experimental. Siguiendo la premisa histórica de que la ciencia avanza de manera colectiva al “subirse a hombros de gigantes” (Newton, 1687), esta plataforma proporciona un entorno integrado y unificado bajo ROS 2 para estructurar todo el ciclo de aprendizaje robótico (*Teleoperar* → *Grabar* → *Entrenar* → *Desplegar*) (Cadene et al., 2026).

El impacto y valor de Rosberto se divide en tres ejes fundamentales:

1. **Democratización del hardware mediante teleoperación remota:** al incorporar un módulo de laboratorio teleoperado compatible con tecnologías de Realidad Virtual (VR) de bajo costo como Meta Quest (phospho, 2024), se facilita el acceso remoto al Unitree G1 Edu real. Estudiantes de diferentes estratos y universidades asociadas podrán cargar y evaluar sus propios modelos en un robot físico real sin la necesidad de que sus instituciones adquieran hardware de alto costo.
2. **Estandarización de datasets y acumulación científica:** el uso nativo del formato universal de datasets de LeRobot de Hugging Face (Cadene et al., 2026) asegura que cada sesión de teleoperación inmersiva se registre como un dataset estandarizado de imitación multimodal. Esto permite la creación de un repositorio centralizado de experiencias robóticas que puede ser compartido, auditado y mejorado por futuras cohortes de estudiantes, construyendo una base sólida de conocimiento colectivo.
3. **Seguridad y eficiencia operativa:** para mitigar el riesgo de daños físicos sobre el hardware real, Rosberto actúa como un middleware supervisor que incluye una capa de seguridad cinemática en ROS 2, la cual intercepta las acciones del modelo para validar límites articulares y de torque en tiempo real antes de su ejecución.

Al automatizar rutinas de parametrización y simplificar la carga de modelos, Rosberto

apunta a reducir el tiempo de parametrización de actuadores y carga de modelos de 1 mes a un 33 %, tomando como referencia plataformas especializadas como The Construct Robotics Institute (The Construct Robotics Institute, 2026), permitiendo que los investigadores de pregrado dediquen su tiempo a la innovación de algoritmos y a la investigación aplicada en el borde (*Edge Computing*), logrando un uso educativo real, estructurado y de alto impacto de la tecnología humanoide.

Objetivos

Objetivo General

Desarrollar una plataforma para la gestión, carga y despliegue de Modelos de Visión y Acción en el robot humanoide Unitree G1 Edu para estandarizar el proceso de investigación universitaria

Objetivos Específicos

- Ordenar y listar modelos vision accion para cargar por red al robot humanoide Unitree G1 Edu.
- Parametrizar todos los actuadores del robot humanoide Unitree G1 Edu en la plataforma, permitiendo que, al seleccionar un modelo visión-acción para cargar por red, se identifique automáticamente cada salida del robot.
- Cargar y ejecutar modelos de visión y acción en el robot humanoide Unitree G1 Edu.
- Realizar una conexión por medio de internet que permita cargar y ejecutar un modelo en el robot humanoide Unitree G1 Edu.
- Reducir el tiempo de parametrización de los actuadores del robot humanoide Unitree G1 Edu y la carga de modelos de 1 mes a un 33 % como se proponen en plataformas especializadas como The Construct Robotics Institute.

Robótica humanoide y aprendizaje robótico

La robótica humanoide constituye un área de investigación orientada al desarrollo de sistemas robóticos capaces de interactuar con entornos diseñados para seres humanos mediante estructuras físicas, capacidades sensoriales y mecanismos de control que reproducen, al menos parcialmente, características de la interacción humana. A diferencia de plataformas robóticas especializadas, los robots humanoides presentan un elevado número de grados de libertad y deben coordinar simultáneamente múltiples articulaciones, sensores y actuadores para ejecutar tareas de locomoción, manipulación e interacción con el entorno. Esta complejidad convierte al desarrollo de comportamientos autónomos en un problema que no depende exclusivamente del diseño mecánico o de los algoritmos de control tradicionales, sino también de la capacidad de adquirir y aprovechar grandes cantidades de información proveniente de la interacción entre el robot y su entorno (Seo et al., 2025).

En este contexto surge el concepto de *robot learning* o aprendizaje robótico, entendido como el conjunto de métodos mediante los cuales un robot aprende políticas de comportamiento a partir de datos, demostraciones humanas, interacción con el entorno o simulaciones. Esta perspectiva representa un cambio frente a la programación convencional de robots, en la cual un desarrollador debe especificar explícitamente reglas, trayectorias y comportamientos para cada tarea. En un sistema basado en aprendizaje, el objetivo consiste en obtener una política que establezca una relación entre las observaciones del robot y las acciones que debe ejecutar.

La necesidad de aprendizaje resulta especialmente relevante en robots humanoides debido a la dimensionalidad del espacio de estados y acciones. Una tarea aparentemente sencilla, como recoger un objeto, puede involucrar simultáneamente información visual, posición y velocidad de las articulaciones, orientación del cuerpo, equilibrio, contacto con superficies y coordinación entre ambas manos. En consecuencia, el desarrollo de políticas mediante métodos de aprendizaje permite abordar comportamientos cuya programación explícita puede resultar costosa y poco escalable.

La ausencia de procesos estandarizados para el despliegue de robots humanoides en tareas

de manipulación y locomoción, y señala que los flujos tradicionales pueden requerir períodos prolongados debido a la recolección manual de datos y a la complejidad del entrenamiento. Por consiguiente, el desafío no se limita al desarrollo de modelos de inteligencia artificial avanzados, sino que también implica optimizar el ciclo completo necesario para transformar datos y demostraciones en comportamientos ejecutables sobre un robot físico.

Aprendizaje por imitación

Uno de los principales paradigmas utilizados para enseñar comportamientos a robots es el aprendizaje por imitación (*Imitation Learning*, IL), mediante el cual una política aprende a reproducir las acciones realizadas por un demostrador. En lugar de definir manualmente una función de recompensa y permitir que el robot explore diferentes comportamientos, el sistema utiliza demostraciones como fuente de información para aproximar la política de un experto.

El aprendizaje por imitación puede formularse de manera simplificada como la búsqueda de una función:

$$\pi_{\theta}(a_t | o_t) \quad (1)$$

donde o_t representa la observación del robot en el instante t , a_t corresponde a la acción ejecutada y π_{θ} representa una política parametrizada mediante los parámetros θ . El proceso de entrenamiento busca modificar dichos parámetros para que las acciones producidas por el modelo sean similares a las acciones presentes en las demostraciones.

Este enfoque resulta particularmente relevante para interfaces de entrenamiento robótico porque permite que el conocimiento humano se convierta directamente en datos de entrenamiento. Una persona puede ejecutar una tarea mediante un mecanismo de teleoperación, mientras el sistema registra simultáneamente las observaciones y acciones. Posteriormente, estas demostraciones pueden emplearse para entrenar una política que reproduzca el comportamiento aprendido.

La literatura reciente identifica el aprendizaje a partir de demostraciones como una alternativa para facilitar la adquisición de habilidades robóticas. Correia y Alexandre (2024)

presentan una revisión del aprendizaje basado en demostraciones y señalan que este paradigma comprende diferentes etapas relacionadas con la adquisición de demostraciones, representación de datos, aprendizaje y evaluación de las habilidades obtenidas. De forma similar, Li et al. (2024) analizan el *Learning from Demonstration* (LfD) como un mecanismo para que los robots adquieran nuevas habilidades a partir de demostraciones humanas y revisan los diferentes modos de demostración, modelos de aprendizaje y métodos de optimización utilizados en este campo.

En el proyecto, el aprendizaje por imitación constituye un componente fundamental, ya que establece una relación directa entre la interfaz propuesta y el proceso de entrenamiento. La interfaz se concibe no solo como un mecanismo para enviar comandos al robot, sino como una herramienta para convertir la interacción humana en datos estructurados que posteriormente pueden emplearse para entrenar políticas (Zare et al., 2023).

Learning from Demonstration y adquisición de habilidades

El concepto de *Learning from Demonstration* (LfD) está estrechamente relacionado con el aprendizaje por imitación, aunque enfatiza el proceso completo mediante el cual un robot adquiere una habilidad a partir de la demostración de un usuario. Una arquitectura de LfD puede incluir las etapas de demostración, captura de datos, procesamiento, representación, aprendizaje y ejecución.

Desde la perspectiva de una plataforma de entrenamiento, estas etapas deben estar integradas de manera coherente. El sistema debe permitir que un usuario inicie una sesión de demostración, controle el robot, almacene los datos, seleccione una política y ejecute el modelo resultante sin la necesidad de configurar manualmente cada componente del sistema.

Esta perspectiva es particularmente importante para la democratización del aprendizaje robótico. Una revisión sobre LfD aplicada a ensamblaje industrial señala que este paradigma puede reducir la necesidad de conocimientos especializados de programación robótica y permitir que trabajadores no expertos enseñen comportamientos a los robots mediante demostraciones (Hernandez Moreno et al., 2024).

Por tanto, la interfaz de entrenamiento puede considerarse como una capa de abstracción entre el usuario y la infraestructura robótica. El usuario proporciona conocimiento mediante una

interacción de alto nivel, mientras que la plataforma se encarga de transformar dicha interacción en información apropiada para los algoritmos de aprendizaje.

Teleoperación robótica

La teleoperación constituye uno de los mecanismos más utilizados para generar demostraciones robóticas. Mediante ella, un operador humano controla directa o indirectamente los movimientos del robot mientras el sistema registra las acciones y observaciones producidas durante la ejecución de una tarea.

En sistemas de manipulación bimanual, la teleoperación puede realizarse mediante robots líderes, dispositivos hápticos, controladores, cámaras, sensores de movimiento o interfaces de realidad virtual. La calidad de la interfaz de teleoperación tiene una influencia directa sobre la calidad de los datos recopilados, debido a que errores, movimientos innecesarios o comportamientos inconsistentes del operador pueden incorporarse posteriormente al conjunto de entrenamiento (Villalobos Rivera & Gallardo Arancibia, 2018).

Un ejemplo representativo es ALOHA, presentado por Zhao et al. (2023), donde se desarrolla un sistema de hardware de bajo costo para manipulación bimanual mediante teleoperación. El sistema permite obtener demostraciones directamente sobre el robot y utilizar posteriormente estas demostraciones para aprendizaje por imitación. El trabajo muestra que un sistema de teleoperación adecuadamente diseñado puede reducir las barreras de acceso a tareas de manipulación fina y posibilitar el entrenamiento con cantidades relativamente pequeñas de demostraciones.

Este principio resulta transferible al contexto de un humanoide como el Unitree G1. Sin embargo, la diferencia fundamental reside en la complejidad del *embodiment*. Mientras que un brazo bimanual puede limitarse a controlar determinados actuadores, un humanoide debe considerar simultáneamente brazos, manos, torso, piernas, orientación corporal y, potencialmente, locomoción. Por esta razón, una interfaz de teleoperación para un humanoide debe proporcionar mecanismos para representar y transformar movimientos humanos en configuraciones compatibles con el robot.

Teleoperación mediante realidad virtual e interfaces inmersivas

Las interfaces de realidad virtual constituyen una evolución de los sistemas tradicionales de teleoperación porque permiten representar el estado del robot y capturar los movimientos del operador de manera espacial e intuitiva. En principio, un usuario puede realizar movimientos similares a los que desea que el robot ejecute, mientras un sistema de *motion retargeting* transforma las configuraciones humanas en comandos para el robot.

Esta característica resulta especialmente relevante para humanoides debido a la necesidad de controlar múltiples grados de libertad. Una interfaz convencional basada exclusivamente en botones o comandos textuales puede dificultar la representación de movimientos complejos. En contraste, una interfaz inmersiva puede permitir una interacción más natural con el sistema.

El proyecto Rosberto contempla una estrategia de teleoperación inmersiva mediante dispositivos de realidad virtual, con el objetivo de facilitar el control bimanual y acelerar la adquisición de demostraciones. En este contexto, la realidad virtual se conceptualiza como una capa adicional de adquisición de datos, superando su función tradicional como interfaz de control.

Calidad y eficiencia de los datos de entrenamiento

En aprendizaje robótico, los datos constituyen uno de los componentes fundamentales del sistema. Una política solo puede aprender comportamientos que estén adecuadamente representados en las demostraciones o datos utilizados durante el entrenamiento. En consecuencia, el diseño de la interfaz de adquisición debe considerar no solamente la cantidad de datos obtenidos, sino también su consistencia, diversidad, sincronización y representación.

Una demostración robótica puede representarse mediante una secuencia temporal:

$$\tau = \{(o_1, a_1), (o_2, a_2), \dots, (o_T, a_T)\} \quad (2)$$

donde o_t puede incluir imágenes, información propioceptiva, posición articular u otras observaciones, mientras que a_t representa las acciones correspondientes.

Para una plataforma de aprendizaje, resulta necesario conservar la correspondencia temporal entre estos elementos. Por ejemplo, una imagen capturada en t debe estar asociada

correctamente con el estado y la acción producida aproximadamente en el mismo instante. Problemas de sincronización pueden degradar el aprendizaje porque el modelo terminaría intentando aprender relaciones incorrectas entre observaciones y acciones.

Además de la sincronización, la diversidad de las demostraciones es relevante. Una política entrenada únicamente con una configuración fija puede presentar dificultades cuando cambian la posición del objeto, iluminación, orientación de la cámara o comportamiento del usuario. Por esta razón, una interfaz de entrenamiento debe facilitar la generación sistemática de múltiples episodios y condiciones.

Estandarización de datasets robóticos

La heterogeneidad del hardware constituye uno de los principales problemas del aprendizaje robótico. Diferentes robots poseen distintas estructuras cinemáticas, sensores, frecuencias de muestreo, espacios de acción y formatos de datos. Si cada plataforma utiliza una representación incompatible, la reutilización de datasets y modelos resulta limitada.

Open X-Embodiment constituye un ejemplo importante de esta tendencia. El proyecto reúne datos procedentes de 22 robots y 21 instituciones, organizándolos en formatos estandarizados para estudiar políticas capaces de transferir conocimiento entre diferentes plataformas. Los autores reportan 527 habilidades y 160.266 tareas, y muestran que una política entrenada con datos provenientes de múltiples robots puede producir transferencia positiva hacia diferentes plataformas (Fang et al., 2023).

Este trabajo introduce un principio fundamental para el proyecto Rosberto: la posibilidad de separar parcialmente los datos de aprendizaje del hardware específico. En lugar de considerar cada robot como un sistema aislado, una arquitectura estandarizada puede representar las experiencias robóticas de modo que puedan ser reutilizadas por diferentes modelos o *embodiments*.

LeRobot como paradigma de estandarización

Dentro de las herramientas contemporáneas para *robot learning*, LeRobot constituye una referencia particularmente relevante para el proyecto. La documentación de Hugging Face

describe LeRobot como una interfaz orientada a proporcionar herramientas para controlar robots reales, registrar y compartir datasets y entrenar políticas de aprendizaje robótico. Su flujo conceptual se organiza como:

$$\text{Teleoperate} \rightarrow \text{Record} \rightarrow \text{Train} \rightarrow \text{Deploy} \quad (3)$$

Este flujo conceptual coincide estrechamente con el ciclo que se busca abstraer en Rosberto.

LeRobot utiliza una interfaz común para los robots compatibles, permitiendo que las políticas y scripts de registro trabajen sobre una abstracción de robot en lugar de depender directamente de cada implementación particular.

Asimismo, su formato *LeRobotDataset* busca estandarizar datos robóticos multimodales, incluyendo señales sensorimotoras, vídeo de múltiples cámaras y metadatos para indexación y visualización.

Esta arquitectura resulta especialmente significativa para Rosberto porque plantea explícitamente utilizar el formato LeRobot como mecanismo de estandarización de los datasets generados mediante teleoperación.

Desde una perspectiva conceptual, puede afirmarse que un sistema como LeRobot intenta abstraer tres niveles:

$$\text{Hardware} \rightarrow \text{Representación de datos} \rightarrow \text{Política} \quad (4)$$

La plataforma propuesta tiene como objetivo extender esta abstracción al contexto específico del humanoide Unitree G1, incorporando mecanismos adicionales de gestión y despliegue.

Políticas de aprendizaje robótico

Una política robótica es una función que transforma las observaciones del sistema en acciones. Matemáticamente puede expresarse como:

$$a_t = \pi_{\theta}(o_t) \quad (5)$$

o, en el caso de políticas que incorporan secuencias temporales:

$$A_{t:t+k} = \pi_{\theta}(O_{t-h:t}) \quad (6)$$

donde $A_{t:t+k}$ representa un conjunto de acciones futuras.

La elección de la política determina en gran medida las características del entrenamiento y del despliegue. Entre las aproximaciones recientes se encuentran políticas basadas en redes convolucionales, *Transformers*, modelos de difusión y modelos fundacionales multimodales.

En este contexto, Action Chunking with Transformers (ACT) representa una contribución importante. Zhao et al. (2023) proponen generar secuencias de acciones en lugar de predecir únicamente una acción individual. Esta estrategia busca reducir la acumulación de errores durante la ejecución y permite representar comportamientos temporales más complejos. En sus experimentos, el sistema ALOHA consiguió realizar varias tareas de manipulación con tasas de éxito de 80–90 % utilizando aproximadamente diez minutos de demostraciones por tarea.

En una plataforma como Rosberto, esto implica que la interfaz debe ser independiente de una única política. El sistema debe permitir la selección de diferentes modelos según las características de la tarea y del hardware.

Diffusion Policies

Otra línea importante corresponde a las políticas basadas en modelos de difusión. Chi et al. (2024) presentan *Diffusion Policy*, que modela una política visuomotora como un proceso de difusión condicionado. El enfoque fue evaluado en múltiples tareas de manipulación y se diseñó específicamente para manejar distribuciones multimodales de acciones, espacios de acción de alta dimensionalidad y problemas de estabilidad durante el entrenamiento.

La relevancia de estas políticas para el proyecto radica en que demuestran cómo la interfaz de entrenamiento puede estar desacoplada del algoritmo utilizado internamente. El usuario puede

proporcionar demostraciones de manera consistente, mientras que la plataforma puede modificar la arquitectura empleada para el aprendizaje a partir de dichas demostraciones.

En consecuencia, una interfaz de entrenamiento generalizable debería abstraer:

$$\text{Usuario} \rightarrow \text{Datos} \quad (7)$$

de:

$$\text{Datos} \rightarrow \text{Modelo} \quad (8)$$

Esta separación permite que una misma infraestructura de adquisición pueda utilizarse posteriormente con ACT, Diffusion Policy, VLA u otras arquitecturas.

Transformers para robótica

La utilización de *Transformers* en robótica responde a la necesidad de modelar dependencias temporales y relaciones complejas entre observaciones y acciones. Mientras que algunos enfoques tradicionales procesan cada instante de forma relativamente independiente, los *Transformers* permiten analizar secuencias y construir representaciones contextuales.

ACT es un ejemplo de esta aplicación en aprendizaje por imitación, mientras que RT-2 demuestra una extensión del paradigma hacia modelos que combinan visión, lenguaje y acción.

La importancia de esta evolución para las interfaces de entrenamiento consiste en que los requisitos de datos se vuelven progresivamente más complejos. Una política moderna puede requerir simultáneamente:

$$\text{Imagen} + \text{Lenguaje} + \text{Estado del robot} \quad (9)$$

y producir:

$$\text{Acciones robóticas} \quad (10)$$

Por esta razón, una plataforma de entrenamiento debe ser capaz de almacenar y gestionar información multimodal.

Vision-Language-Action Models

Los modelos *Vision-Language-Action* (VLA) representan una evolución hacia sistemas capaces de conectar información visual y lenguaje natural con acciones robóticas. RT-2 constituye uno de los trabajos fundamentales en esta dirección. El modelo utiliza conocimiento procedente de modelos visión-lenguaje preentrenados y lo adapta al control robótico, representando las acciones dentro del mismo marco de predicción utilizado para otros tokens. Los experimentos muestran mejoras en generalización a objetos y situaciones no observadas durante el entrenamiento específico del robot.

Conceptualmente, un VLA puede representarse como:

$$\pi_{\theta}(I_t, L_t, S_t) \rightarrow A_t \quad (11)$$

donde I_t corresponde a la información visual, L_t a la instrucción lingüística, S_t al estado del robot y A_t a la acción.

Este paradigma modifica significativamente el concepto tradicional de entrenamiento robótico. En lugar de entrenar una política completamente nueva para cada tarea, el objetivo puede consistir en adaptar o ajustar un modelo previamente entrenado.

Esta transición es relevante para Rosberto, dado que la plataforma propuesta contempla la carga y el despliegue de modelos de acción avanzados como ACT, π_0 y GR00T.

OpenVLA y modelos abiertos

OpenVLA representa otra etapa en la evolución de los VLA. Kim et al. (2024) presentan un modelo abierto de 7 mil millones de parámetros entrenado utilizando una colección diversa de aproximadamente 970.000 demostraciones robóticas. Los autores plantean que los modelos preentrenados pueden permitir adaptar políticas existentes a nuevas tareas mediante *fine-tuning*, en lugar de entrenar cada comportamiento desde cero.

Esta característica tiene consecuencias importantes para la accesibilidad de la robótica. Si el conocimiento aprendido previamente puede reutilizarse, la interfaz deja de estar centrada exclusivamente en “entrenar un modelo” y pasa a gestionar un ciclo más amplio:

Seleccionar modelo → Seleccionar dataset → Adaptar → Evaluar → Desplegar (12)

Por lo tanto, una plataforma de investigación debe ir más allá de ofrecer opciones básicas para iniciar el entrenamiento y permitir la gestión integral de modelos, datasets, configuraciones, extit checkpoints y despliegues.

Modelos fundacionales para robótica humanoide

Los modelos fundacionales aplicados a robótica buscan ampliar todavía más el concepto de política generalista. En lugar de aprender exclusivamente una tarea sobre un robot determinado, estos modelos buscan aprovechar grandes cantidades de información procedente de diferentes robots, tareas y modalidades.

El concepto de *embodiment* resulta central en este contexto. Dos robots pueden recibir una instrucción idéntica pero requerir acciones diferentes debido a sus distintas arquitecturas físicas. Por ello, una política generalista debe aprender una representación suficientemente abstracta para transferir conocimiento entre *embodiments*.

Open X-Embodiment constituye un ejemplo de este enfoque al utilizar datos provenientes de múltiples plataformas para entrenar políticas generalistas.

En el ámbito humanoide, NVIDIA presenta GR00T como una familia de modelos orientados a robots humanoides. La arquitectura utiliza como entradas secuencias de vídeo, comandos de lenguaje y estado propioceptivo, y produce secuencias de movimientos articulares. La documentación actual también señala la incorporación del Unitree G1 dentro de los *embodiments* considerados en versiones recientes de los modelos.

Esta tendencia resalta la importancia de contar con una infraestructura que permita cargar diferentes modelos sobre un mismo robot. De este modo, el robot físico permanece constante

mientras se modifican las políticas empleadas.

Simulación y aprendizaje Sim-to-Real

El entrenamiento directo sobre robots físicos presenta limitaciones relacionadas con seguridad, desgaste del hardware, tiempo de experimentación y costo de interacción. Por ello, la simulación constituye una herramienta fundamental para desarrollar y evaluar políticas antes de transferirlas al mundo real.

El paradigma *Sim-to-Real* busca entrenar o preentrenar una política en simulación y posteriormente transferirla al robot físico. Sin embargo, esta transferencia presenta dificultades debido a la diferencia entre las propiedades simuladas y las condiciones reales (Ghasemi & Ebrahimi, 2024).

Isaac Lab desarrollado sobre Isaac Sim una plataforma para la simulación robótica (Gao et al., 2026) constituye un ejemplo contemporáneo de infraestructura orientada a este problema. El framework integra simulación física acelerada por GPU, renderizado, sensores, modelos de actuadores, recopilación de datos y herramientas de *domain randomization*, además de soportar aprendizaje por refuerzo e imitación.

Desde el punto de vista de Rosberto, la simulación representa una posible extensión del ciclo de entrenamiento:

$$\text{Simulación} \rightarrow \text{Entrenamiento} \rightarrow \text{Validación} \rightarrow \text{Robot real} \quad (13)$$

La interfaz puede abstraer parte de las diferencias entre el entorno simulado y el físico, lo que permite a los investigadores emplear un flujo de trabajo unificado.

Gestión del ciclo de vida de modelos

A medida que los sistemas robóticos incorporan modelos de mayor tamaño y complejidad, el entrenamiento deja de ser una operación aislada. Un experimento puede producir múltiples versiones de datasets, configuraciones, *checkpoints* y políticas.

Por ello, una plataforma de investigación robótica requiere mecanismos de gestión del ciclo de vida del modelo. Conceptualmente, este ciclo puede expresarse como:

Dataset → Entrenamiento → Checkpoint → Evaluación → Despliegue → Retroalimentación → Nuevo Dataset
(14)

Esta estructura convierte el aprendizaje robótico en un proceso iterativo. El robot ejecuta una política, las nuevas experiencias pueden convertirse en datos adicionales y estos datos pueden emplearse para mejorar la siguiente versión de la política.

La complejidad de los frameworks actuales constituye una barrera importante para usuarios que no poseen experiencia profunda en programación robótica, middleware, CUDA, ROS, controladores o entrenamiento de redes neuronales.

Una interfaz de alto nivel busca encapsular parte de esta complejidad. En lugar de exigir al usuario configurar individualmente cada componente, puede ofrecer operaciones conceptuales como:

- Seleccionar robot.
- Seleccionar tarea.
- Recolectar demostraciones.
- Entrenar modelo.
- Evaluar.
- Desplegar.

LeRobot constituye un ejemplo actual de esta filosofía. Su documentación plantea explícitamente el objetivo de reducir la barrera de entrada a la robótica mediante una interfaz común, datasets compartidos, políticas preentrenadas y herramientas para registrar, entrenar y desplegar modelos.

Además, LeLab proporciona una interfaz gráfica que permite configurar robots, realizar teleoperación, recolectar datasets, entrenar políticas y ejecutar modelos desde una misma aplicación, reduciendo la necesidad de memorizar comandos de línea de comandos.

Aunque actualmente LeLab presenta compatibilidad limitada a determinadas plataformas, el concepto arquitectónico es relevante para Rosberto, dado que la interfaz puede funcionar como una capa de orquestación sobre un conjunto de herramientas de aprendizaje robótico.

Abstracción de hardware

Una característica fundamental para una plataforma de este tipo es la abstracción del hardware. En un sistema tradicional, el algoritmo de aprendizaje puede depender directamente de nombres de articulaciones, puertos, controladores, sensores y protocolos específicos.

Una arquitectura abstracta puede definir una interfaz común:

$$\text{RobotInterface} = \{\text{connect}, \text{observe}, \text{act}, \text{disconnect}\} \quad (15)$$

De esta manera, el modelo interactúa con una representación lógica del robot en lugar de depender directamente de su implementación física.

LeRobot utiliza precisamente una interfaz abstracta para representar robots compatibles, donde cada robot implementa operaciones comunes como conexión, lectura de observaciones, envío de acciones y desconexión.

Para Rosberto, esta idea es especialmente relevante, ya que permite que la plataforma no quede completamente acoplada a un único controlador de bajo nivel. El Unitree G1 puede constituir el *embodiment* inicial, mientras que la arquitectura puede mantener una separación entre:

$$\text{Capa de aplicación} \rightarrow \text{Capa de abstracción del robot} \rightarrow \text{SDK / ROS / Controladores} \rightarrow \text{Unitree G1} \quad (16)$$

Middleware y orquestación

El concepto de middleware resulta fundamental para comprender la propuesta de Rosberto. Un middleware puede actuar como una capa intermedia que conecta diferentes componentes tecnológicos sin exigir al usuario interactuar directamente con cada uno de ellos.

En el trabajo propuesto los componentes potenciales incluyen:

Usuario $\rightarrow$ Interfaz Rosberto (17)

$\downarrow$

(18)

{
 Teleoperación
 Dataset
 Entrenamiento
 Modelos
 Evaluación
 Deployment
 } (19)

$\downarrow$

(20)

ROS / SDK / APIs $\rightarrow$ Unitree G1 (21)

Esta arquitectura posibilita la separación entre la experiencia del usuario y la implementación técnica.

La relevancia de este enfoque aumenta cuando se consideran modelos heterogéneos. ACT, Diffusion Policy, VLA y modelos fundacionales pueden tener diferentes requisitos de entrada, formatos de *checkpoint*, frecuencias de inferencia y representaciones de acciones. Un middleware puede encargarse de convertir las representaciones entre componentes.

Reproducibilidad en investigación robótica

La reproducibilidad constituye otro fundamento conceptual para el proyecto. En un entorno universitario, diferentes estudiantes deberían poder repetir experimentos utilizando el mismo dataset, modelo, configuración y hardware.

La estandarización de datasets contribuye a este objetivo, pero también es necesario conservar información relacionada con la configuración experimental. Un experimento debería poder asociarse conceptualmente con:

$$E = (D, M, C, H, P) \quad (22)$$

donde D representa el dataset, M el modelo, C la configuración, H el hardware y P los parámetros de entrenamiento.

Una plataforma que gestione estos elementos puede facilitar la repetición y comparación de experimentos.

Se que busca estandarizar la investigación universitaria y permitir que el conocimiento generado en diferentes experimentos sea reutilizable por otros investigadores.

Democratización de la investigación en robótica

La democratización de la robótica puede entenderse como la reducción de las barreras económicas, técnicas y de conocimiento necesarias para experimentar con sistemas robóticos avanzados.

Podría beneficiar a estudiantes de pregrado, investigadores y profesores, y universidades. En particular, plantea que una plataforma estandarizada podría reducir la necesidad de que cada estudiante adquiriera conocimientos profundos sobre drivers de bajo nivel y permitir un mejor aprovechamiento de hardware costoso mediante acceso remoto y seguro.

La democratización no implica la eliminación de la complejidad técnica del sistema, sino su traslado desde el usuario final hacia componentes de infraestructura reutilizables.

Así, el objetivo de una interfaz de alto nivel no es reemplazar ROS, SDK, frameworks de aprendizaje o controladores, sino orquestarlos detrás de una abstracción orientada a tareas.

Unitree G1 Education Edition como plataforma de investigación

El Unitree G1 constituye el *embodiment* físico sobre el cual se plantea validar la plataforma Rosberto. En este contexto, el robot no debe considerarse únicamente como un

actuador, sino como un sistema experimental que integra percepción, locomoción, manipulación, control y procesamiento.

El desafío de entrenar modelos sobre un humanoide es mayor que en sistemas de manipulación de menor dimensionalidad debido a la necesidad de coordinar múltiples subsistemas. Las tareas pueden involucrar simultáneamente manipulación bimanual, equilibrio, locomoción y percepción.

El proyecto se enfoca en el robot Unitree G1 Edu como plataforma objetivo y propone desarrollar una infraestructura para estandarizar la investigación sobre dicho robot.

Esta delimitación es relevante porque permite transformar una problemática general de la robótica humanoide en un problema concreto de ingeniería: desarrollar una interfaz capaz de abstraer las operaciones necesarias para entrenar y desplegar modelos de inteligencia artificial sobre una plataforma humanoide específica.

The Construct Robotics Institute

La complejidad técnica y el tiempo requerido para la adopción de tecnologías de robots humanoides, resulta fundamental analizar las estructuras formativas vigentes en la industria. The Construct Robotics Institute, se ha consolidado como una plataforma de educación en línea y desarrollo enfocado en robotica, centrada en el ecosistema ROS (Robot Operating System) y la inteligencia artificial aplicada, el programa de formacion Humanoid Robotics Masterclass (The Construct Robotics Institute, 2026) representa el estándar actual de capacitación técnica, organizando la curva de aprendizaje en etapas que incluyen desde el diseño mecánico y la integración electrónica hasta sistemas de control avanzado, simulación y la implementación de políticas de aprendizaje por refuerzo en plataformas reales como el Unitree G1.

Integración de los conceptos en el ciclo de aprendizaje robótico

Los conceptos anteriores pueden integrarse en un único ciclo:

Demostración humana → Teleoperación → Dataset → Entrenamiento → Política → Evaluación → Despliegue

(23)

La teleoperación permite generar las demostraciones. Los datasets proporcionan una representación estructurada de las experiencias. Los algoritmos de aprendizaje transforman estos datos en políticas. Las políticas son evaluadas mediante simulación o interacción física y finalmente desplegadas sobre el robot.

Después del despliegue, las nuevas experiencias pueden volver al dataset:

Robot → Nueva experiencia → Dataset → Reentrenamiento

(24)

Por lo tanto, el aprendizaje robótico puede entenderse como un ciclo continuo y no como un proceso lineal.

En este contexto, una interfaz como Rosberto puede desempeñar el papel de conectar las diferentes etapas del ciclo, la integración de la gestión de modelos VLA, la estandarización de datasets y la teleoperación inmersiva.

Relación conceptual con Rosberto

Con base en los fundamentos expuestos, Rosberto puede conceptualizarse como una plataforma middleware de alto nivel cuyo objetivo es reducir la complejidad operacional del ciclo de aprendizaje robótico sobre el Unitree G1.

Su arquitectura conceptual puede representarse mediante cinco capas:

1. **Capa de interacción.** Proporciona al investigador una interfaz para configurar experimentos, seleccionar tareas y controlar procesos.
2. **Capa de adquisición.** Permite realizar teleoperación y registrar demostraciones multimodales.
3. **Capa de datos.** Estandariza, almacena y organiza las experiencias obtenidas durante las sesiones de entrenamiento.

4. **Capa de aprendizaje.** Gestiona diferentes políticas y modelos, incluyendo aprendizaje por imitación, políticas generativas y modelos VLA.
5. **Capa de despliegue.** Transforma el modelo entrenado en una política ejecutable sobre el Unitree G1.

La arquitectura puede resumirse como:

$$\boxed{\text{Usuario} \rightarrow \text{Interfaz} \rightarrow \text{Datos} \rightarrow \text{Modelo} \rightarrow \text{Evaluación} \rightarrow \text{Unitree G1}} \quad (25)$$

La contribución principal de la plataforma no radica en el desarrollo de un nuevo algoritmo de aprendizaje, sino en la integración y abstracción de tecnologías existentes para reducir la complejidad del ciclo de investigación.

Los trabajos de ALOHA, Open X-Embodiment, Diffusion Policy, RT-2 y OpenVLA muestran diferentes etapas de esta evolución: desde la adquisición eficiente de demostraciones y el aprendizaje de habilidades específicas hasta la utilización de grandes datasets y modelos multimodales para desarrollar políticas más generales.

Paralelamente, plataformas como LeRobot e Isaac Lab muestran que la infraestructura utilizada para desarrollar modelos se está convirtiendo en un componente fundamental de la investigación. LeRobot integra control de hardware, adquisición de datos, datasets, entrenamiento y despliegue en un flujo común, mientras que Isaac Lab proporciona una infraestructura orientada al aprendizaje robótico a gran escala en simulación (Cadene et al., 2026).

A partir de esta convergencia se identifica el fundamento conceptual de Rosberto: una plataforma orientada a reducir la distancia existente entre el investigador y la infraestructura necesaria para entrenar y desplegar modelos sobre un robot humanoide. En lugar de reemplazar los frameworks y algoritmos existentes, la propuesta busca integrarlos bajo una interfaz común, facilitando la adquisición de demostraciones, la gestión de datasets, el entrenamiento y la implementación de modelos sobre el Unitree G1 Education Edition.

Metodología

Este proyecto aborda una metodología de acción-resultado, en la que se propone una acción que, al llevar a cabo su ejecución, da como resultado el cumplimiento de cada uno de los objetivos específicos del proyecto. Esta correspondencia directa asegura que la viabilidad de Rosberto no dependa de suposiciones, sino de la validación empírica de los componentes de software y control integrados sobre el Unitree G1 Edu.

A continuación se presenta la Tabla 1 con las acciones que se realizarán para cumplir cada uno de los objetivos del proyecto.

Cuadro 1

Matriz de Acciones Metodológicas y Resultados Esperados (MAM-RE)

Objetivo Específico	Acción Metodológica	Resultado Esperado
OE-01: Indexación y ordenamiento. Ordenar y listar modelos visión-acción para cargar por red al Unitree G1 Edu.	Desarrollo del repositorio de modelos VLA: construcción del backend y frontend de Rosberto para indexar, clasificar y visualizar modelos VLA (ACT, π_0 , GR00T) compatibles con el Unitree G1.	Módulo catálogo de modelos: interfaz que lista los modelos disponibles, detallando arquitectura, hiperparámetros y compatibilidad de datasets.
OE-02: Parametrizar actuadores. Parametrizar los actuadores del robot para identificar automáticamente cada salida al cargar un modelo.	Algoritmo de mapeo cinemático: desarrollo de un módulo de traducción que asocia las acciones generadas por la política $\pi_\theta(a_t o_t)$ con los motores y articulaciones del robot real (29 DoF).	Módulo de mapeo y parametrización automática: módulo de articulaciones que recibe el vector de salida del modelo VLA y autoconfigura el SDK del Unitree G1 sin intervención manual.

Objetivo Específico	Acción Metodológica	Resultado Esperado
OE-03: Carga y ejecución. Cargar y ejecutar modelos de visión y acción en el Unitree G1 Edu.	Pipeline de inferencia en el borde: creación de un proceso de ejecución en tiempo real dentro del middleware que reciba datos propioceptivos y flujos visuales, realice la inferencia localmente y envíe comandos de torque/posición.	Runtime de inferencia funcional: demostración experimental del Unitree G1 ejecutando tareas de locomoción o manipulación con los modelos cargados.
OE-04: Conectividad remota. Realizar una conexión por internet que permita cargar y ejecutar un modelo de forma remota.	Arquitectura de red y teleoperación remota: desarrollo de un servicio de red para la transferencia remota de checkpoints de modelos y datos sensoriales desde terminales externas y cascos de realidad virtual.	Servicio de red de Rosberto: conexión por internet funcional que permite a un usuario remoto subir un modelo VLA entrenado y comandar la ejecución del robot.

Objetivo Específico	Acción Metodológica	Resultado Esperado
OE-05: Optimización temporal. Reducir el tiempo de parametrización de actuadores y carga de modelos de 1 mes a un 33 %, tomando como referencia plataformas especializadas como The Construct Robotics Institute (The Construct Robotics Institute, 2026).	Benchmarking de tiempos y pruebas de usabilidad: medición sistemática del tiempo de preparación, configuración y despliegue usando Rosberto frente al flujo de comandos tradicional.	Informe de rendimiento temporal: comparación de tiempos que verifica el cumplimiento de la meta de reducción de 1 mes a un 33 % en los tiempos operativos.

El desarrollo metodológico de Rosberto se organiza en cinco fases secuenciales e iterativas:

1. Diagnóstico y análisis de requerimientos.
2. Diseño arquitectónico del middleware (cinco capas).
3. Desarrollo de la capa de datos e imitation learning.
4. Integración de modelos de percepción zero-shot.
5. Validación de seguridad, benchmarking y optimización.

Fase I: Diagnóstico y análisis de requerimientos técnicos. Consiste en la identificación

de las limitaciones operativas del Unitree G1 Edu y la recopilación de los requerimientos de hardware y software necesarios para el entorno académico:

- **Análisis del embodiment:** estudio cinemático del Unitree G1 Edu (29 DoF), identificando sus sensores propioceptivos y los límites de par de sus motores.
- **Requerimientos de software:** definición del ecosistema compatible con CUDA, PyTorch, LeRobot y cascos de realidad virtual Meta Quest.

Fase II: Diseño de arquitectura del middleware. Siguiendo los principios de abstracción de hardware y separación de responsabilidades expuestos en el marco teórico, se decide construir la capa de despliegue del middleware sobre ROS 2, y se diseña la arquitectura lógica de Rosberto en las cinco capas ya definidas conceptualmente: interacción, adquisición, datos, aprendizaje y despliegue.

Fase III: Desarrollo de la capa de datos e imitation learning. Esta fase aborda la recolección estandarizada de datos mediante teleoperación:

- **Adquisición de demostraciones en realidad virtual:** integración del casco Meta Quest para capturar de manera espacial y bimanual los movimientos del operador humano.
- **Sincronización de datos multimodales:** desarrollo de un mecanismo que asocie temporalmente las observaciones visuales (o_t) con las acciones cinemáticas (a_t) bajo la secuencia de demostración $\tau = \{(o_1, a_1), (o_2, a_2), \dots, (o_T, a_T)\}$ definida en el marco teórico.
- **Estandarización bajo LeRobot:** exportación de los datos recolectados al formato *LeRobotDataset* para crear datasets reutilizables de acceso colectivo (Cadene et al., 2026).

Fase IV: Integración de modelos de percepción zero-shot. Para reducir el riesgo de daños en un hardware de alto costo durante las etapas de experimentación estudiantil, se prioriza la percepción zero-shot sobre el robot físico en lugar de entrenar políticas en entornos virtuales:

- **Percepción zero-shot:** integración de modelos base como FoundationPose y SAM 3D para permitir al robot interactuar con nuevos objetos sin necesidad de entrenamientos específicos por pieza ni de construir un entorno de simulación propio.

Fase V: Validación de seguridad, benchmarking y optimización. La fase final valida la eficiencia y seguridad cinemática del sistema antes del despliegue en laboratorios de pregrado:

- **Capa de seguridad cinemática:** implementación de un nodo supervisor que monitorea el par y los límites angulares de las articulaciones del robot, interceptando comandos anómalos de las redes neuronales y gestionando una parada de emergencia por software.
- **Pruebas comparativas de rendimiento temporal:** ejecución del protocolo experimental comparando el tiempo de configuración tradicional frente al despliegue automatizado con Rosberto. Esta comparación mide el tiempo operativo que le toma a una persona parametrizar los actuadores y poner en marcha un modelo, no la velocidad de carga o inferencia del modelo dentro del robot; el análisis estadístico de los tiempos medidos valida si se alcanza la reducción propuesta de 1 mes a un 33 % en dicho tiempo operativo humano.

Resultados

Conclusiones

Referencias

- Bjorck, J., Castañeda, F., Cherniadev, N., Da, X., Ding, R., Fan, L., Fang, Y., Fox, D., Hu, F., Huang, S., Jang, J., Jiang, Z., Kautz, J., Kundalia, K., Lao, L., Li, Z., Lin, Z., Lin, K., Liu, G., ... Zhu, Y. (2025). GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. <https://arxiv.org/abs/2503.14734>
- Cadene, R., Aliberts, S., Capuano, F., Aractingi, M., Zouitine, A., Kooijmans, P., Choghari, J., Russi, M., Pascal, C., Palma, S., Shukor, M., Moss, J., Soare, A., Aubakirova, D., Lhoest, Q., Gallouédec, Q., & Wolf, T. (2026). LeRobot: An Open-Source Library for End-to-End Robot Learning. <https://arxiv.org/abs/2602.22818>
- Fang, H.-S., Fang, H., Tang, Z., Liu, J., Wang, C., Wang, J., Zhu, H., & Lu, C. (2023). RH20T: A Comprehensive Robotic Dataset for Learning Diverse Skills in One-Shot. <https://arxiv.org/abs/2307.00595>
- Gao, S., Pagnucco, M., Bednarz, T., & Song, Y. (2026). NVIDIA Isaac Sim: Enabling Scalable, GPU-Accelerated Simulation for Robotics. <https://arxiv.org/abs/2606.03551>
- Ghasemi, M., & Ebrahimi, D. (2024). Introduction to Reinforcement Learning. <https://arxiv.org/abs/2408.07712>
- Hernandez Moreno, V., Jansing, S., Polikarpov, M., Carmichael, M. G., & Deuse, J. (2024). Obstacles and opportunities for learning from demonstration in practical industrial assembly: A systematic literature review. *Robotics and Computer-Integrated Manufacturing*, 86, 102658. <https://doi.org/https://doi.org/10.1016/j.rcim.2023.102658>
- Newton, I. (1687). *Philosophiæ Naturalis Principia Mathematica* ["Si he logrado ver más lejos ha sido porque he subido a hombros de gigantes."]. Royal Society.
- phospho. (2024). *phosphobot: Control AI robots — community-driven UI middleware for recording datasets and training action models* [Accessed 2026-08-30]. <https://github.com/phospho-app/phosphobot>
- Seo, Y., Sferrazza, C., Chen, J., Shi, G., Duan, R., & Abbeel, P. (2025). Learning Sim-to-Real Humanoid Locomotion in 15 Minutes. <https://arxiv.org/abs/2512.01996>

The Construct Robotics Institute. (2026). Humanoid Robotics Masterclass [Accessed: 2026-08-30].

Villalobos Rivera, A., & Gallardo Arancibia, J. (2018). Diseño e implementación de un observatorio robótico teleoperado basado en Robot Operating System. *Ingeniare. Revista Chilena de Ingeniería*, 26, 12-19. <https://doi.org/10.4067/S0718-33052018000500012>

Yan, Y., Liao, Y., & Ye, L. (2026). A Rapid Deployment Pipeline for Autonomous Humanoid Grasping Based on Foundation Models. <https://arxiv.org/abs/2604.17258>

Zare, M., Kebria, P. M., Khosravi, A., & Nahavandi, S. (2023). A Survey of Imitation Learning: Algorithms, Recent Developments, and Challenges. <https://arxiv.org/abs/2309.02473>